

**КИЇВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ
ІМЕНІ ТАРАСА ШЕВЧЕНКА**

Факультет комп'ютерних наук та кібернетики
Кафедра обчислювальної математики

Кваліфікаційна робота
на здобуття ступеня бакалавра
за спеціальністю 113 Прикладна математика
на тему:

**Аналіз впливу макроекономічних і соціальних факторів на прогнозування
цін оренди житла в Києві**

Виконав студент 4-го курсу
ООП «Прикладна математика»
Чернуха Данііл Максимович


(підпис)

Науковий керівник:
доцент кафедри обчислювальної математики
кандидат фізико-математичних наук, доцент
Затула Дмитро Васильович


(підпис)


Засвідчую, що в цій роботі
немає запозичень з праць інших авторів
без відповідних посилань.
Студент


(підпис)

Роботу розглянуто й допущено до
захисту
на засіданні кафедри обчислювальної
математики

« 03 » червня 2026 р.,
протокол № 17

Завідувач кафедри
доктор фіз.-мат. наук, професор
Ляшко С. І.


(підпис)

РЕФЕРАТ

Обсяг роботи: 62 сторінки, 16 ілюстрацій, 24 таблиці, 21 джерело посилань.

МНОЖИННА РЕГРЕСІЯ, КОЕФІЦІЄНТ ДЕТЕРМІНАЦІЇ, ГОМОСКЕДАСТИЧНІСТЬ, МУЛЬТИКОЛІНЕАРНІСТЬ, КРОС-ВАЛІДАЦІЯ, ПРОГНОЗУВАННЯ, ПАНЕЛЬНІ ДАНІ, РОБАСТНІ СТАНДАРТНІ ПОМИЛКИ, АВТОКОРЕЛЯЦІЯ, ФУНКЦІОНАЛЬНІ ПЕРЕТВОРЕННЯ, ЕФЕКТИ ВЗАЄМОДІЇ, СТОХАСТИЧНЕ МОДЕЛЮВАННЯ.

Об'єктом дослідження є ринок оренди житла в Києві, зокрема динаміка цін на оренду одно-, дво- та трикімнатних квартир у довгостроковій перспективі та макроекономічні й соціальні фактори, що впливають на їх зміну.

Предметом дослідження є математичні моделі множинної лінійної регресії для прогнозування цін оренди житла.

Метою роботи є побудова, діагностика та порівняльний аналіз регресійних моделей для прогнозування цін оренди житла в Києві на основі макроекономічних і соціальних показників.

Інструменти розроблення: мова програмування R (пакети `lmtest`, `car`, `leaps`, `plm`, `fixest`, `sandwich`, `ggplot2` та інші), середовище RStudio.

Результати дослідження: зібрано та опрацьовано широкий набір статистичних даних (19 потенційних предиктори за період 2015–2026 рр.). Побудовано серію регресійних моделей для одно-, дво- та трикімнатних квартир, а також комбіновану модель із категоріальною змінною. Проведено повний цикл діагностики: перевірку мультиколінеарності, лінійності, гомоскедастичності, нормальності та автокореляції залишків. Застосовано функціональні перетворення змінних, ефекти взаємодії, робастні стандартні помилки (HAC, DK) та методи крос-валідації. Окремо виконано стохастичне моделювання динаміки чисельності населення Києва з використанням апарату диференціальних рівнянь.

ЗМІСТ

ВСТУП	6
1 ОСНОВНІ ТЕОРЕТИЧНІ ВІДОМОСТІ	8
1.1 Модель множинної лінійної регресії	8
1.2 Перевірка значимості	10
1.2.1 Перевірка значимості регресійної моделі	10
1.2.2 Перевірка значимості коефіцієнтів	11
1.3 Стандартизація залишків	12
1.4 Перевірка адекватності моделі	12
1.4.1 Лінійність	13
1.4.2 Гомоскедастичність	15
1.4.3 Некорельованість похибок	16
1.4.4 Нормальність	18
1.4.5 Незалежність предикторів	19
1.5 Вибір функціонального перетворення	20
1.6 Валідація моделі	21
1.7 Інші показники якості моделі	24
2 ВИБІРКА ТА ПОТЕНЦІЙНІ ФАКТОРИ ВПЛИВУ	25
2.1 Початковий аналіз даних	26
2.2 Моделювання чисельності населення Києва	28
3 ПОБУДОВА МОДЕЛІ	31
3.1 Схема побудови моделі	31
3.2 Побудова моделі для першого періоду	33
3.2.1 Модель на основі цін однокімнатних квартир	35

3.2.2	Модель на основі цін двокімнатних квартир	44
3.2.3	Модель на основі цін трикімнатних квартир	46
3.2.4	Комбінована модель	47
3.2.5	Використання змодельованої змінної	50
3.3	Побудова моделі для другого періоду	50
3.3.1	Модель на основі цін однокімнатних квартир	52
3.3.2	Модель на основі цін двокімнатних квартир	53
3.3.3	Модель на основі цін трикімнатних квартир	53
3.3.4	Комбінована модель	54
ВИСНОВКИ		55
ПЕРЕЛІК ДЖЕРЕЛ ПОСИЛАННЯ		56
ДОДАТКИ		59

СКОРОЧЕННЯ ТА УМОВНІ ПОЗНАКИ

AIC	інформаційний критерій Акаїке (Akaike Information Criterion);
BIC	байєсівський інформаційний критерій (Bayesian Information Criterion);
C_p	статистика Меллоуза;
DK	стандартні помилки Дрісколла–Края;
HAC	стандартні помилки, стійкі до гетероскедастичності та автокореляції;
HC3	робастні стандартні помилки (Heteroskedasticity-Consistent, тип 3);
LOESS	локально зважене згладжування (Locally Estimated Scatterplot Smoothing);
MSE	середньоквадратична помилка (Mean Squared Error);
MS_{Res}	середній квадрат залишків;
PRESS	сума квадратів передбачених залишків (Predicted Residual Error Sum of Squares);
RMSE	корінь із середньоквадратичної помилки (Root Mean Squared Error);
R^2	коефіцієнт детермінації;
R_{adj}^2	скоригований коефіцієнт детермінації;
R_{pred}^2	прогностичний коефіцієнт детермінації;
SS_{Res}	залишкова сума квадратів;
SS_{Tot}	загальна сума квадратів;
VIF	фактор інфляції дисперсії (Variance Inflation Factor);
МНК	метод найменших квадратів.

ВСТУП

Оцінка сучасного стану об'єкта дослідження. Ринок оренди житла в Києві характеризується високою волатильністю, особливо в періоди економічних криз та геополітичної нестабільності. Ціни на оренду реагують на широкий спектр факторів: від коливань валютного курсу до змін у чисельності населення столиці. У зв'язку з цим виникає потреба в аналітичних інструментах, які дозволяють не лише якісно оцінювати поточний стан ринку, а й кількісно прогнозувати ціни з прийнятною точністю.

Актуальність роботи та підстави для її виконання. Прогнозування цін на оренду житла є важливою задачею сучасної економетрики, що має як теоретичне, так і практичне значення. Складність цієї задачі полягає в необхідності одночасного врахування значної кількості різнорідних факторів — макроекономічних показників, демографічних даних, індексів ризику тощо. Одним із найпоширеніших підходів до розв'язання таких задач є множинна лінійна регресія, яка дозволяє не лише отримувати прогнози, а й оцінювати відносну важливість кожного з факторів. Окрім власне прогнозування, важливим аспектом є дотримання регресійних припущень (лінійність, гомоскедастичність, незалежність, нормальність залишків) та застосування робастних методів оцінювання у випадку їх порушення.

Мета й завдання роботи. Метою кваліфікаційної роботи є побудова та порівняльний аналіз моделей множинної лінійної регресії для прогнозування цін оренди одно-, дво- та трикімнатних квартир у Києві. Для досягнення цієї мети поставлено такі завдання:

- зібрати та опрацювати статистичні дані про ціни оренди житла в Києві за період 2016–2026 рр., а також дані про потенційні фактори впливу на ціну;
- провести попередній аналіз даних (виявлення викидів, кореляційний аналіз, перевірку мультиколінеарності);

- побудувати множинні регресійні моделі для різних типів квартир;
- провести діагностику моделей (перевірку регресійних припущень) та застосувати методи виправлення порушень (функціональні перетворення, робастні стандартні помилки);
- реалізувати стохастичне моделювання динаміки чисельності населення Києва та дослідити вплив змодельованого притоку ціну.

Об’єкт дослідження. Об’єктом дослідження є ринок оренди житла в Києві, зокрема динаміка цін на оренду одно-, дво- та трикімнатних квартир у період з 2016 по 2026 рік, а також макроекономічні та соціальні фактори, що впливають на їх зміну.

Предмет дослідження. Предметом дослідження є математичні моделі множинної лінійної регресії для прогнозування цін оренди житла, методи діагностики та виправлення порушень регресійних припущень, а також методи стохастичного моделювання демографічних показників.

Методи дослідження. У роботі використано методи множинного регресійного аналізу, методи перевірки статистичних гіпотез, методи відбору змінних, методи крос-валідації, а також чисельні методи оптимізації для калібрування параметрів динамічних моделей.

Інструменти розроблення. У якості програмного середовища для побудови моделей використано мову програмування R в інтегрованому середовищі RStudio. Основні пакети: `lmtest`, `car`, `leaps`, `plm`, `fixest`, `sandwich`, `ggplot2`, `optimx`. Посилання на репозиторій проекту див. у переліку джерел [7].

Можливі сфери застосування. Результати роботи можуть бути використані для аналізу тенденцій на ринку оренди житла, розроблення цінових стратегій, прийняття рішень щодо інвестування в житлову нерухомість, а також для подальших наукових досліджень у галузі економетричного моделювання та прогнозування.

1 ОСНОВНІ ТЕОРЕТИЧНІ ВІДОМОСТІ

1.1 Модель множинної лінійної регресії

Виклад основного матеріалу цього підрозділу базується на роботі [17].

Нехай маємо вибірку об'єму n :

$$\{(y_i, x_{i1}, x_{i2}, \dots, x_{ik})\}_{i=1}^n,$$

де y_i — значення залежної змінної для i -го спостереження, x_{ij} — значення j -ї незалежної змінної для i -го спостереження, k — кількість незалежних змінних. Залежну змінну y будемо називати відгуком, а незалежні змінні x_j , $j = \overline{1, k}$ — регресорами, або предикторами.

Розглянемо модель множинної регресії в матричному вигляді:

$$y = X\beta + \varepsilon, \quad (1)$$

де

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1k} \\ 1 & x_{21} & \cdots & x_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{nk} \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

Тут β — невідомі параметри моделі, ε — вектор випадкових похибок.

Для оцінювання параметрів моделі традиційно використовується метод найменших квадратів (МНК): знайти оцінку $\hat{\beta}$, яка мінімізує наступну функцію:

$$S(\beta) = \sum_{i=1}^n \varepsilon_i^2 = \varepsilon' \varepsilon = (y - X\beta)'(y - X\beta).$$

Перепишемо функцію $S(\beta)$ у вигляді

$$S(\beta) = y'y - \beta'X'y - y'X\beta + \beta'X'X\beta = y'y - 2\beta'X'y + \beta'X'X\beta,$$

оскільки $\beta'X'y \in \mathbb{R}^{1 \times 1}$.

МНК-оцінка задовольняє співвідношенню

$$\left. \frac{\partial S}{\partial \beta} \right|_{\hat{\beta}} = -2X'y + 2X'X\hat{\beta} = 0,$$

звідки отримуємо **нормальні рівняння**

$$X'X\hat{\beta} = X'y \quad (2)$$

або

$$\hat{\beta} = (X'X)^{-1}X'y. \quad (3)$$

Використовуючи МНК-оцінку (3), маємо

$$\hat{y} = X\hat{\beta} = X(X'X)^{-1}X'y =: Hy, \quad (4)$$

де H називається **проекційною матрицею**.

Різниця між спостережуваним значенням y_i та підібраним значенням $\hat{y}_i$ називається **залишком** e_i моделі. Сума квадратів залишків

$$SS_{Res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2$$

є фундаментальним показником точності моделі. SS_{Res} лежить в основі інших показників якості, зокрема, в основі **коефіцієнта детермінації**:

$$R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_{Res}}{SS_T},$$

де $SS_T = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = SS_R + SS_{Res}$ — загальна варіація моделі.

Очевидно, що

$$e = (I - H)y, \quad (5)$$

де $e = (e_1, e_2, \dots, e_n)'$.

Тут і надалі будемо припускати, що $\text{Var}[\varepsilon_i] = \sigma^2 \equiv \text{const} \quad \forall i = \overline{1, n}$ та $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad i \neq j$. Тоді можна показати, що середній квадрат залишків

$$MS_{Res} = \frac{SS_{Res}}{n - p}, \quad p = k + 1$$

є незміщеною оцінкою σ^2 [17], тобто

$$E[MS_{Res}] = E[\hat{\sigma}^2] = \sigma^2.$$

Явище, коли дисперсія похибок є сталою, називається **гомоскедастичністю**. Інакше — **гетероскедастичністю**.

Визначимо дисперсію МНК-оцінок $\hat{\beta}_j$, враховуючи, що

$$\text{Var}[y] = \text{Var}[X\beta + \varepsilon] = \text{Var}[\varepsilon] = \sigma^2 I,$$

I — одинична матриця. Використовуючи вигляд МНК-оцінки (3), маємо

$$\begin{aligned} \text{Var}[\hat{\beta}_j] &= \text{Var}[(X'X)^{-1}X'y] = (X'X)^{-1}X'\text{Var}[y][(X'X)^{-1}X']' = \\ &= \sigma^2(X'X)^{-1}X'X(X'X)^{-1} = \sigma^2(X'X)^{-1} =: \sigma^2 C. \end{aligned} \quad (6)$$

1.2 Перевірка значимості

1.2.1 Перевірка значимості регресійної моделі

Для перевірки гіпотез, крім припущень про некорельованість похибок ε_i та гомоскедастичність, також вимагаємо, щоб вони були розподілені за нормальним

законом, тобто

$$\varepsilon_i \sim N(0, \sigma^2).$$

Перевірка значимості моделі використовується для того, щоб встановити, чи має відгук y лінійний зв'язок хоча б із одним із регресорів $x_1, x_2, \dots, x_k$. Перевіряємо гіпотезу

$$\begin{aligned} H_0 : \forall j = \overline{1, k} \quad \beta_j &= 0, \\ H_1 : \exists j \in \{1, 2, \dots, k\} : \quad \beta_j &\neq 0. \end{aligned}$$

Регресійна сума квадратів визначається як

$$SS_R = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

Тоді можна довести [17], що

$$F_0 = \frac{SS_R/k}{SS_{Res}/(n-p)} = \frac{MS_R}{MS_{Res}} \sim F_{k, n-p}.$$

Отже, відхиляємо нульову гіпотезу на рівні значимості α , якщо

$$F_0 > F_{\alpha, k, n-p}.$$

1.2.2 Перевірка значимості коефіцієнтів

Аналогічно до перевірки значимості моделі, здійснюємо перевірку регресійних коефіцієнтів окремо:

$$H_0 : \beta_j = 0,$$

$$H_1 : \beta_j \neq 0.$$

Обчислюємо t -статистику [17]:

$$t_0 = \frac{\hat{\beta}_j}{\text{SE}[\hat{\beta}_j]} = \frac{\hat{\beta}_j}{\sqrt{\hat{\sigma}^2 C_{jj}}} \sim t_{n-p},$$

де C_{jj} — j -й діагональний елемент матриці C , визначеної у формулі (6).

Відхиляємо гіпотезу H_0 на рівні значимості α , якщо

$$|t_0| > t_{\frac{\alpha}{2}, n-p}.$$

1.3 Стандартизація залишків

У багатьох випадках може бути корисно працювати зі стандартизованими (нормованими) залишками, особливо при виявленні викидів.

Введемо **студентизовані залишки**:

$$r_i = \frac{e_i}{\hat{\sigma}^2 \sqrt{1 - h_{ii}}}, \quad i = \overline{1, n}, \quad (7)$$

де h_{ii} — i -й діагональний елемент проекційної матриці H . Зауважимо, що $E[r_i] = 0$ та $\text{Var}[r_i] = 1$.

Серйознішим підходом до стандартизації залишків є зовнішнє масштабування залишків. Ідея полягає у використанні оцінки σ^2 , обчисленої на основі набору даних без i -го спостереження. Позначимо цю оцінку як $S_{(i)}^2$. Можна показати, що

$$S_{(i)}^2 = \frac{(n-p)MS_{Res} - \frac{e_i^2}{1-h_{ii}}}{n-p-1}. \quad [17]$$

Використаймо цю оцінку для обчислення **зовнішнього студентизованого залишку** (R-student):

$$t_i = \frac{e_i}{S_{(i)}^2 \sqrt{1 - h_{ii}}}, \quad i = \overline{1, n}. \quad (8)$$

1.4 Перевірка адекватності моделі

До цього часу зробили фундаментальні припущення:

- зв'язок між відгуком та предикторами є лінійним;
- $\varepsilon_i \sim N(0, \sigma^2)$, $\sigma^2 \equiv \text{const.}$

Також припускатимемо, що між предикторами відсутній сильний лінійний зв'язок. У цьому розділі наведемо методи перевірки кожного із цих припущень, а також шляхи виправлення потенційних порушень.

1.4.1 Лінійність

Діаграми розсіювання залишків

Найпростішим способом перевірки лінійності зв'язку між відгуком та предикторами є візуалізація діаграми розсіювання залишків e_i проти передбачених моделлю значень $\hat{y}_i$. Ознакою нелінійності є наявність патерну на графіку — найчастіше хвиле- або U-подібного.

Нелінійність може бути наслідком пропущеної в моделі змінної або неправильної специфікації моделі. Отже, нелінійність часто можна виправити, додавши пропущену змінну або застосувавши функціональне перетворення над відгуком та/або регресорами.

Корисною також є візуалізація діаграми розсіювання залишків e_i проти значень регресорів x_{ij} . Нелінійний патерн на графіку вказує на те, що реальний зв'язок між y та x_{ij} є нелінійним.

Графік доданої змінної та CR-Plot

Недоліком звичайних графіків залишків є те, що вони не повністю відображають частинний вплив регресора за умови наявності інших змінних у моделі. Це враховує **графік доданої змінної**, або графік частинної регресії. Для побудови такого графіка як y , так і x_j регресують за рештою $k - 1$ змінних моделі, після чого обчислюються залишки обох моделей — $e(y|x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k)$ та $e(x_j|x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k)$ відповідно. Зображення цих залишків один навпроти одного дає інформацію про характер частинного зв'язку y із регресором x_j : якщо x_j входить до моделі лінійно, то зображені залишки будуть розташовуватися вздовж прямої з ненульовим нахилом. Нахил цієї прямої буде рівний коефіцієнту

$\hat{\beta}_j$ у множинній моделі [17].

CR-Plots (з англ. *Component plus Residual plots* — графіки компоненти плюс залишки) також використовуються для візуальної перевірки лінійності з урахуванням впливу всіх інших змінних. Для кожного предиктора x_j обчислюється спеціальна змінна, яка називається **частинним залишком** (partial residual):

$$\text{PartialRes}_j = \hat{\beta}_j x_j + e,$$

де:

- $\hat{\beta}_j x_j$ — компонента, тобто внесок j -го предиктора у передбачене значення;
- $e = y - X\hat{\beta}$.

Інтуїтивний зміст цієї величини полягає в тому, що ми фіксуємо ту частину передбаченого значення, яку пояснює саме x_j , і додаємо до неї все, що модель не змогла пояснити (залишки).

На графіку будуються дві лінії: регресійна пряма на основі PartialRes, яка показує той зв'язок, який припускає модель (лінійний), а також LOESS-згладжування, яке показує реальну форму зв'язку, що спостерігається в даних [11]. Якщо побудовані лінії накладаються одна на одну, то зв'язок між y та x_j є лінійним.

RESET-тест

Крім візуальної перевірки «на око» існують також статистичні тест на лінійність зв'язку. Зокрема, тест Дж. Б. Ремзі, або **RESET-тест** (англ. — *Regression Specification Error Test*), який використовується для перевірки пропущених квадратичних або кубічних членів [19].

Розглядаються дві моделі:

- базова: $y = X\beta + \varepsilon$;
- розширена: $y = X\beta + \gamma_1 \hat{y}^2 + \gamma_2 \hat{y}^3 + \varepsilon$, де $\hat{y} = X\hat{\beta}$ — передбачені значення базової моделі.

Якщо модель є лінійною, то $\hat{y}^2 \hat{y}^3$ не повинні додавати пояснювальної сили. Отже, логічним є сформулювати наступні гіпотези:

$$H_0 : \gamma_1 = \gamma_2 = 0,$$

$$H_1 : \gamma_1 \neq 0 \vee \gamma_2 \neq 0.$$

Перевірка гіпотези виконується аналогічно до загальної процедури F-тесту, описаної в підрозділі 1.2.1:

$$F_0 = \frac{(SS_{Res} - SS_{Res}^{Ext})/2}{SS_{Res}^{Ext}/(n - (p + 2))} \sim F_{2, n-(p+2)},$$

де SS_{Res}^{Ext} — сума квадратів залишків розширеної моделі.

1.4.2 Гомоскедастичність

Діаграми розсіювання залишків

Гомоскедастичність також можна перевірити за допомогою діаграм розсіювання залишків, описаних у п. 1.4.1. У випадку несталої дисперсії залишків діаграми можуть демонструвати патерни воронки або дуги — що вказує на те, що зі збільшенням значень $\hat{y}_i$ (або x_{ij}) змінюється і розкид залишків.

Зауваження. При побудові діаграм розсіювання залишків рекомендованим є використання стбюдентизованих або зовнішньо стбюдентизованих залишків, оскільки їх дисперсія, на відміну від звичайних залишків, не залежить від розташування відповідних їм спостережень у просторі регресорів.

Якщо в моделі наявна гетероскедастичність, то її можна виправити шляхом додавання пропущеної змінної або застосування функціональних перетворень. Якщо ж гетероскедастичність виправити не вдається, то можна використати робастні оцінки стандартних помилок параметрів моделі НАС або НСЗ (див. статті [18] та [15] відповідно). За наявності гетероскедастичності стандартні помилки МНК-оцінок — а тому і показники статистичної значимості — стають ненадій-

ними.

Тест Бройша-Пагана

Формально тест Бройша-Пагана перевіряє гіпотезу про незалежність залишків від предикторів [10]. Побудуємо допоміжну модель, де в ролі відгука виступають квадрати залишків початкової моделі (4):

$$e^2 = \gamma_0 + \gamma_1 x_1 + \dots + \gamma_k x_k + u.$$

Якщо хоча б один із коефіцієнтів γ_j є відмінним від нуля, то це означає, що дисперсія залишків залежить від значень предикторів, тобто наявна гетероскедастичність. Отже, поставимо наступні гіпотези:

$$H_0 : \gamma_1 = \gamma_2 = \dots = \gamma_k = 0,$$

$$H_1 : \exists j \in \{1, \dots, k\} : \gamma_j \neq 0.$$

Обчислимо коефіцієнт детермінації допоміжної регресії R_{aux}^2 .

$$LM = n \cdot R_{aux}^2 \sim \chi_k^2.$$

Відхиляємо нульову гіпотезу, якщо $LM > \chi_{\alpha, k}^2$.

1.4.3 Некорельованість похибок

Коли похибки є залежними між собою, кажуть, що має місце **автокореляція**. Порушення припущення про некорельованість похибок є надзвичайно поширеним у часових рядах. При наявності автокореляції в даних стандартні помилки МНК-оцінок можуть бути некоректними.

На відміну від нелінійності або гетероскедастичності, автокореляцію неможливо виправити шляхом застосування функціональних перетворень, оскільки кореляція залишків (похибок) залежить від структури даних, а не від форми мо-

делі. Натомість використовують інші методи оцінювання регресійних параметрів, зокрема, узагальний метод найменших квадратів (див. [17], с. 188 — 190). Проте замість перерахунку МНК-оцінок можна використати НАС-оцінки стандартних помилок, оскільки автокореляція впливає лише на них [18].

Кореляція та графік залишків у часовому ряді

Нехай e_t — залишок у момент часу t . **Автокореляцією k -го порядку** називається залежність між значеннями послідовності $\{e_t\}_{t=1}^n$, віддаленими на k одиниць часу. Автокореляцію порядку k можна обчислити безпосередньо:

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^n e_t e_{t-k}}{\sum_{t=1}^n e_t^2}.$$

Проте найчастіше виникають проблеми саме з автокореляцією першого порядку. Таку залежність можна виявити візуально, зобразивши послідовність $\{e_t\}_{t=1}^n$ на діаграмі розсіювання.

Тест Дарбіна–Уотсона

Тест Дарбіна–Уотсона [12] перевіряє гіпотезу про відсутність автокореляції першого порядку. Статистика тесту обчислюється за формулою:

$$DW = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2}.$$

Зауважимо, що $0 \leq DW \leq 4$, причому $DW \approx 2$ свідчить про відсутність автокореляції. Статистика DW пов'язана з коефіцієнтом автокореляції першого порядку $\hat{\rho}_1$ наближеним співвідношенням:

$$DW \approx 2(1 - \hat{\rho}_1).$$

Сформулюємо гіпотези:

$$H_0 : \rho_1 = 0,$$

$$H_1 : \rho_1 \neq 0.$$

Для прийняття рішення використовують критичні значення d_L та d_U , які залежать від кількості спостережень n та кількості предикторів k . Якщо $DW < d_L$ — відхиляємо нульову гіпотезу; якщо $DW > d_U$ — нульова гіпотеза не відхиляється; якщо $d_L < DW < d_U$ — результат невизначений.

1.4.4 Нормальність

Q-Q Plot

Припущення нормальності використовується тільки при перевірці статистичних гіпотез і при побудові довірчих інтервалів отриманих оцінок.

Одним із найбільш поширених графічних методів перевірки нормальності є **Q-Q Plot** (з англ. *Quantile-Quantile Plot* — графік квантиль-квантиль). На цьому графіку по осі абсцис відкладаються теоретичні квантілі нормального розподілу $\mathcal{N}(0, 1)$, а по осі ординат — вибірові квантілі студентизованих залишків (7).

Якщо залишки мають нормальний розподіл, точки на Q-Q Plot мають лежати вздовж прямої $y = x$. Відхилення від цієї прямої свідчать про порушення нормальності.

Зауваження. Для вибірок великого обсягу ($n > 30$) невеликі відхилення від нормальності не є критичними в силу центральної граничної теореми.

Тест Шапіро–Вілکا

Нехай залишки моделі e_i впорядковані за зростанням. Для перевірки гіпотези про нормальність розподілу можна використати тест Шапіро–Вілکا [20]. Статистика тесту:

$$W = \frac{(\sum_{i=1}^n a_i e_i)^2}{\sum_{i=1}^n (e_i - \bar{e})^2},$$

$a_1, a_2, \dots, a_n$ — вагові коефіцієнти, які обчислюються як компоненти вектора

$$a = \frac{m^T V^{-1}}{\sqrt{m^T V^{-1} V^{-1} m}},$$

де $m = (m_1, m_2, \dots, m_n)^T$ — вектор математичних сподівань порядкових статистик стандартного нормального розподілу, а V — їхня коваріаційна матриця. Ці величини залежать лише від обсягу вибірки n і не залежать від самих даних.

Якщо дані нормальні, то $W \approx 1$; якщо ні — $W < 1$.

Перевіряємо наступні гіпотези:

H_0 : залишки мають нормальний розподіл,

H_1 : залишки не мають нормального розподілу.

p -value обчислюється на основі спеціальних таблиць або апроксимацій, отриманих Шапіро та Вілком у їхній оригінальній роботі [20]. Відхиляємо нульову гіпотезу на рівні значущості α , якщо p -value $< \alpha$.

1.4.5 Незалежність предикторів

На відміну від розглянутих вище припущень щодо випадкових похибок ε_i , які необхідні для коректності статистичних висновків, припущення про предиктори потрібне для того, щоб модель взагалі можливо було побудувати. Із вигляду МНК-оцінки (3) зрозуміло, що $\hat{\beta}$ існує лише в тому випадку, коли матриця $X'X$ є невиродженою. Проте для отримання адекватної моделі вимагати лінійної незалежності стовпців матриці X недостатньо. У випадку, коли регресори достатньо добре описують лінійний зв'язок між собою, статистичні висновки про вплив кожного окремого регресора на відгук або про стандартну помилку коефіцієнта при ньому можуть бути хибними [17]. У такому разі такі предиктори називають **мультиколінеарними**.

Для перевірки попарної мультиколінеарності, тобто кореляції між двома пре-

дикторами, достатньо побудувати кореляційну матрицю предикторів, обчисливши для кожної пари коефіцієнт кореляції:

$$\rho_{jk} = \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \sum_{i=1}^n (x_{ik} - \bar{x}_k)^2}}.$$

$|\rho_{jk}| > 0.9$ свідчить про сильний лінійний зв'язок x_j та x_k , $j \neq k$. У такому разі слід розглянути варіант вилучення однієї зі змінних із моделі.

Однієї кореляційної матриці може бути недостатньо при дослідженні мультиколінеарності, оскільки так ми враховуємо тільки взаємозв'язки між парами змінних. Розглянемо **фактор інфляції дисперсії VIF** (англ. — *Variance Inflation Factor*), який визначається наступним чином:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad (9)$$

де R_j^2 — коефіцієнт детермінації моделі, де x_j регресує за рештою змінних, тобто в якості відгуку моделі виступає x_j , а в якості предикторів — $x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k$. Якщо x_j добре пояснюється рештою змінних, то VIF_j буде високим.

Також можна показати, що

$$\text{VIF}_j = C_{jj} \quad [17].$$

Ще однією мірою мультиколінеарності є число обумовленості матриці $X'X$:

$$\kappa = \frac{\lambda_{\max}}{\lambda_{\min}},$$

де $\lambda_{\max}, \lambda_{\min}$ — найбільше та найменше власні числа матриці $X'X$ відповідно.

1.5 Вибір функціонального перетворення

Введемо поняття **інформаційного критерію Акаїке** (англ. — *Akaike Information Criterion, AIC*) [8], який вносить штраф моделі за її складність. У випадку лінійної

регресії AIC має вигляд:

$$AIC = n \ln \left(\frac{SS_{Res}}{n} \right) + 2p.$$

Для вибору оптимального функціонального перетворення відгуку або предикторів здійснимо перебір стандартних трансформацій і порівняємо якість отриманих моделей за показником AIC. Для кожного предиктора x_j розглядаються такі трансформації: x_j (без змін), $\ln x_j$, $\sqrt{x_j}$, x_j^2 , $1/x_j$. Кожне перетворення розглядається у двох варіантах: із заміною початкової змінної ($-x_j + f(x_j)$) та з додаванням до початкової ($+f(x_j)$). Для кожної з отриманих моделей AIC, після чого обирається та трансформація, яка забезпечує найбільше зменшення AIC порівняно з початковою моделлю. У випадку, якщо AIC найкращої моделі не є значно меншим за AIC, то таке перетворення сенсу не має.

Функціональні перетворення над відгуком підбираються аналогічно, але з тією відмінністю, що розглядається лише варіант заміни y на $f(y)$. Функціональне перетворення над відгуком також можна обрати методом Бокса–Кокса, описаним у статті [9].

Зауваження. У першу чергу функціональні перетворення варто обирати на основі порушень регресійних припущень, якщо вони наявні. Проте на практиці функціональне перетворення, яке значно покращує AIC, зазвичай виправляє неадекватність моделі.

1.6 Валідація моделі

Після побудови регресійної моделі на наявній вибірці даних варто перевірити, наскільки добре вона узагальнюється на нових даних. Іншими словами, потрібно дослідити, чи не є побудована модель перенавченою. На практиці зазвичай немає доступу до нових даних, тому доцільним є застосування методів крос-валідації (перехресної перевірки), зокрема k-fold та forward chaining.

Метод k-fold крос-валідації

Нехай $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ — початкова вибірка, яку розбито на k частин $\mathcal{D}_1, \mathcal{D}_2, \dots$,

Для кожної частини $\mathcal{D}_j$ виконуємо наступне:

1. будуємо модель на даних $\mathcal{D} \setminus \mathcal{D}_j$ (усі частини, крім j -ї) та фіксуємо $\hat{y}_{-j}$;
2. обчислюємо середньоквадратичну помилку на тестовій частині $\mathcal{D}_j$:

$$MSE_j = \frac{1}{|\mathcal{D}_j|} \sum_{(x_i, y_i) \in \mathcal{D}_j} (y_i - \hat{y}_{-j}(x_i))^2.$$

Підсумковою оцінкою якості моделі є середня помилка за всіма k ітераціями:

$$MSE_{CV} = \frac{1}{k} \sum_{j=1}^k MSE_j.$$

Аналогічно можна отримати R_{CV}^2 , обчислюючи на кожній ітерації коефіцієнт детермінації поточної моделі.

Метод forward chaining

На відміну від звичайної k -fold крос-валідації, метод forward chaining враховує часову структуру даних. Цей алгоритм є імітацією процесу прогнозування тих значень, на яких модель не навчалась. Нехай $\mathcal{D} = \{(x_t, y_t)\}_{t=1}^n$ — початкова вибірка, впорядкована за часом. Зафіксуємо початковий розмір навчальної вибірки n_0 та горизонт прогнозування h . Тоді $\forall i \geq 1$:

1. формуємо навчальну вибірку з перших $n_0 + (i - 1)$ спостережень:

$$\mathcal{D}_{train}^{(i)} = \{(x_t, y_t)\}_{t=1}^{n_0+i-1};$$

2. формуємо тестову вибірку з наступних h спостережень:

$$\mathcal{D}_{test}^{(i)} = \{(x_t, y_t)\}_{t=n_0+i}^{n_0+i+h-1};$$

3. будуємо модель на навчальній вибірці $\mathcal{D}_{train}^{(i)}$ та фіксуємо підібрані значення відгуку $\hat{y}^{(i)}$;

4. обчислюємо середньоквадратичну помилку на тестовій вибірці $\mathcal{D}_{test}^{(i)}$:

$$MSE_i = \frac{1}{h} \sum_{(x_t, y_t) \in \mathcal{D}_{test}^{(i)}} \left(y_t - \hat{y}^{(i)}(x_t) \right)^2.$$

Процес продовжується доти, доки тестова вибірка не досягне кінця доступних даних. Підсумковою оцінкою якості моделі є середня помилка за всіма кроками:

$$MSE_{FC} = \frac{1}{m} \sum_{i=1}^m MSE_i,$$

де m — загальна кількість ітерацій. Найчастіше використовують горизонт $h = 1$ (передбачення на один крок уперед). Початковий розмір навчальної вибірки n_0 має бути достатнім для побудови моделі).

Прогнозний коефіцієнт детермінації

Найпростішим способом перевірки якості моделі на нових даних є обчислення **прогнозного коефіцієнта детермінації** R_{pred}^2 . Нехай $e_{(i)} = y_i - \hat{y}_{(i)}$, де $\hat{y}_{(i)}$ — підібране значення y_i моделлю на основі всіх спостережень, крім i -го. Розглянемо статистику

$$\text{PRESS} = \sum_{i=1}^n (y_i - \hat{y}_{(i)})^2 = \sum_{i=1}^n e_{(i)}^2.$$

Тоді R_{pred}^2 визначається як

$$R_{pred}^2 = 1 - \frac{\text{PRESS}}{SS_T}.$$

Зауваження. Можна довести, що $e_{(i)} = \frac{e_i}{1-h_{ii}}$ [17].

1.7 Інші показники якості моделі

Альтернативно до АІС можна використовувати **інформаційний критерій Байєса** (англ. — *Bayesian Information Criterion, BIC*) [21]:

$$\text{BIC} = n \ln \left(\frac{SS_{Res}}{n} \right) + p \ln(n),$$

який вносить більший штраф за складність моделі.

Ще одним поширеним критерієм є **статистика Меллоуза** C_p [16], яка оцінює сумарне зміщення моделі:

$$C_p = \frac{SS_{Res}}{\hat{\sigma}^2} - (n - 2p),$$

тут SS_{Res} — середній квадрат залишків підмоделі, $\hat{\sigma}^2$ — оцінка дисперсії із повної моделі. Для адекватної моделі значення C_p має бути близьким до p ; якщо $C_p \gg p$, модель має значне зміщення.

Для врахування кількості предикторів також використовують **скоригований коефіцієнт детермінації**:

$$R_{adj}^2 = 1 - \frac{SS_{Res}/(n - p)}{SS_{Tot}/(n - 1)},$$

який, на відміну від звичайного R^2 , не зростає автоматично при додаванні нових змінних, що робить його придатним для порівняння моделей із різною кількістю предикторів.

2 ВИБІРКА ТА ПОТЕНЦІЙНІ ФАКТОРИ ВПЛИВУ

Побудуємо лінійну модель для прогнозування ціни оренди житла одно-, дво- та трикімнатних квартир у Києві. Для цього розглянемо набір потенційних предикторів, перелік яких подано в таблиці 1.

Таблиця 1 — Потенційні фактори впливу на ціну оренди житла

Фактор	Скорочення	Період	Періодичність	К-сть спост.
Офіційний курс євро	Євро	23.11.2015 – 01.06.2026	щоденна	3844
Ціна оренди 1-кімн. квартир, грн	K1	23.11.2015 – 05.06.2026	щоденна	3766
Ціна оренди 2-кімн. квартир, грн	K2	23.11.2015 – 05.06.2026	щоденна	3766
Ціна оренди 3-кімн. квартир, грн	K3	23.11.2015 – 05.06.2026	щоденна	3766
Офіційний курс долара	Долар	23.11.2015 – 31.05.2026	щоденна	3843
Активність на ринку житла, шт.	Активність	01.01.2021 – 01.07.2025	квартальна	19
Боргове навантаження домогосподарств, млрд грн	БоргНавантаж	01.03.2020 – 01.09.2024	квартальна	19
Введення в експлуатацію житла, млн кв. м	ВведЖитла	01.01.2020 – 01.04.2025	квартальна	22
Індекс геополітичних ризиків	ІГР	01.02.2008 – 01.05.2026	місячна	220
Індекс фінансового стресу	ІФС	29.04.2008 – 28.11.2025	щоденна	4419
Індекс цін на вторинному ринку	ІЦЖВ	01.03.2017 – 01.03.2025	квартальна	33
Індекс цін на первинному ринку	ІЦЖП	01.03.2017 – 01.03.2025	квартальна	33
Індекс цін у будівництві	ІЦБ	01.11.2015 – 01.02.2025	місячна	112
Індекс цін на вторинному ринку–2	ІЦЖВ	01.12.2018 – 01.10.2025	місячна	83
Індекс цін на первинному ринку–2	ІЦЖП	01.12.2018 – 01.10.2025	місячна	83
Індекс цін у будівництві–2	ІЦБ	01.12.2018 – 01.10.2025	місячна	83
Обсяг чистих гривневих кредитів, грн	ЧистГрнКред	01.12.2018 – 01.10.2025	місячна	83
Оцінка доходів населення, % до ВВП	ОцінкаДоходів	01.03.2021 – 01.12.2024	квартальна	16
Рівень доларизації коштів фізосіб і бізнесу, %	РівДолар	01.01.2014 – 01.12.2024	місячна	132
Середній рівень доларизації, %	РівДолар	01.01.2014 – 01.11.2025	місячна	143
Річні темпи зміни коштів фізосіб, %	ТемпЗмінКошт	01.12.2018 – 01.10.2025	квартальна	35
Кредитний портфель (весь), %	КредПортфель	01.01.2023 – 01.07.2024	місячна	19
Нові кредити (за місяць), %	НовіКредити	01.01.2023 – 01.07.2024	місячна	19
Споживчі настрої домогосподарств	ІндМатСтан	01.12.2019 – 01.11.2025	місячна	72
Чисельність населення Києва	ЧисНасел	01.11.2015 – 01.02.2022	місячна	76

Статистичні дані про ціни оренди житла взято із веб-сайту M² Bomber [1]; дані про ІГР — з веб-сайту М. Яковелло Country-specific GPR index [14]; дані про чисельність населення Києва — Держстат [2]; дані про курси валют — НБУ [5]; ретша даних — зі звітів про фінансову стабільність НБУ за грудень 2024 [3] та грудень 2025 років [3].

У таблиці 1 Середній рівень доларизації визначається, як середнє арифмети-

чне рівня доларизації коштів фізосіб та рівня доларизації коштів юридичних осіб. Необхідність додавання такої змінної мотивується відсутністю статистичних даних про загальний рівень доларизації фізосіб і бізнесу з початку 2025 року. Зауважимо, що коефіцієнт кореляції між РівДолар і середнім РівДолар становить приблизно 0.997, тому до моделі доцільніше включати той предиктор, що має більше спостережень.

2.1 Початковий аналіз даних

Звернімо увагу, що кількість спостережень предикторів сильно варіюється. Якщо ми будемо розглядати всі предиктори відразу в одній моделі, то отримаємо вибірку об'єму 16, що не є надзвичайно малою цифрою для такої кількості змінних. Отже, будемо розглядати декілька моделей на основі різної кількості спостережень. Оскільки в якості відгуку ми маємо ціни, то в першу чергу вимагаємо, щоб наявними були дані для цін.

Зобразивши графіки динаміки кожного з предикторів, наведених вище (рис. 1), дані логічно розбити на два періоди: до повномасштабного вторгнення та після. Доцільним є поділ періоду саме по 01.01.2022, оскільки показник ІГР почав стімко зростати за кілька місяців до повномасштабної війни. Також звернімо увагу, що декілька перших спостережень про чисельність населення є екстремальними, та після них спостерігається стрибок показника за нереалістично короткий проміжок часу. Це можна пояснити можливою зміною методики підрахунку чисельності населення Держстатом або надходженням внутрішньо переміщених осіб із зони АТО/ООС або прифронтових територій. На основі сказаного, вилучимо перші спостереження з вибірки. Отже, працюємо з двома періодами: 01.01.2016 — 31.12.2021 та 01.01.2022 — 01.06.2026. Проте зазначимо, що вибірки можуть звужитись при відборі змінних до моделей.




Рис. 1 — Графіки динаміки кожної зі змінних

2.2 Моделювання чисельності населення Києва

Логічно припустити, що чим більше нових мешканців з'являється в Києві, тим вищою буде середня ціна оренди житла, оскільки нові мешканці створюють попит на ринку (потреба в житлі). Офіційні дані про притік населення до Києва наявні [2], проте вони враховують тільки офіційну статистику, тобто зареєстрованих прибулих. При чому кореляція такої змінної із цінами не така висока, як можна було б припускати. Також графік кількості прибулих є «вибухоподібним»: на початку кожного періоду (року) спостерігається різке спадання (див. рис. 14, додаток В). Така сезонність не є неприродною, проте це не відмінняє того, що, можливо, саме ця періодичність зумовлена непостійним обліком притоку населення. Також зауважимо, що офіційних даних по кількості населення (і взагалі міграції населення) із лютого 2022 року немає, оскільки у військовий час облік населення не ведеться.

Отже, викликає необхідність у моделюванні динаміки чисельності населення Києва. Для цього використаємо підхід, запропонований Овчинніковою та Куликовим [6], який ґрунтується на марківській моделі руху активного населення. У рамках цього підходу розглядаються три групи (стани марківського процесу): мешканці Києва, населення України без Києва та українці, що перебувають за кордоном. Основне рівняння моделі має вигляд:

$$n(t + \Delta) = n(t) - R\Delta n(t) + P'R\Delta n(t) + a\Delta,$$

де:

- $n(t)$ — вектор чисельності груп на момент часу t ;
- Δ — крок моделі (у даному дослідженні $\Delta = 1$ місяць);
- R — діагональна матриця коефіцієнтів вибуття r_i для кожної групи;
- P — матриця переходів між групами, елемент p_{ij} якої означає частку вибу-

лих з групи i , що переходять до групи j ;

- a — вектор зовнішніх змін (природний приріст, міграція з-за меж системи тощо).

Другий доданок $R\Delta n(t)$ відповідає за кількість вибулих з кожної групи за час Δ . Третій доданок $P'R\Delta n(t)$ описує розподіл вибулих між групами згідно з матрицею переходів P . Отже, для моделювання притоку населення до Києва змодельуємо чисельність, фіксуючи на кожному часовому кроці вектор $P'R\Delta n(t)$, оскільки його елементи відповідають чисельності прибулих у момент часу t

Нехай матриця переходів P має вигляд:

$$P = \begin{pmatrix} 0 & 1 & 0 \\ p_{21} & 0 & 1 - p_{21} \\ p_{31} & 1 - p_{31} & 0 \end{pmatrix},$$

де $p_{21} = p_{21}(t)$. В якості параметра $p_{21}(t)$ візьмемо офіційні дані про коефіцієнт прибуття в Київ на одну особу в момент часу t . Нехай також $r_1 = r_1(t)$ — коефіцієнт вибуття з Києва на одну особу; $r_3 = r_3(t)$ — коефіцієнт прибуття в Україну на одну особу. Всі ці статистичні дані взяті з Держстату [2].

Початкова чисельність населення Києва та України без Києва нам відома: $n_1(0) = 2.863074$ та $n_2(0) = 39.74$ відповідно (млн). Решту параметрів $p_{31}, n_3(0), r_2$ оцінюємо оптимізаційним методом так, щоб мінімізувати функцію втрат, яка є сумою двох середньоквадратичних похибок:

$$\text{Loss} = \text{MSE}_{\text{pop}} + \text{MSE}_{\text{inflow}},$$

де

$$\text{MSE}_{\text{pop}} = \frac{1}{T} \sum_{t=1}^T (n_t^{\text{real}} - n_t^{\text{sim}})^2,$$

$$\text{MSE}_{\text{inflow}} = \frac{1}{T} \sum_{t=1}^T (\text{inflow}_t^{\text{real}} - \text{inflow}_t^{\text{sim}})^2.$$

Тут n_t^{real} — фактична чисельність населення Києва за даними Держстату, n_t^{sim} — змодельована чисельність, $\text{inflow}_t^{\text{real}}$ — офіційна кількість прибулих до Києва, $\text{inflow}_t^{\text{sim}}$ — змодельований приток, а T — кількість спостережень. Оптимізація виконується методом L-BFGS-B з обмеженнями на параметри.

Початкові умови для трьох груп задано наступним чином:

$$n_1(0) = 2.863074 \text{ млн}, \quad n_2(0) = 39.74 \text{ млн}, \quad n_3(0) = 6.0 \text{ млн}.$$

Нехай $n_2(0)$ теж входить у параметри, які потрібно відкалібрувати. Результат наведено в таблиці 2.

Таблиця 2 — Результати оптимізації параметрів моделі

r_2	p_{31}	$n_2(0)$	$n_3(0)$	Loss
0.02475	0.10326	39.74212	6.00775	0.00289

Графіки змодельованої чисельності та притоку, а також кореляційну матрицю зі змодельованими факторами у довоєнний час див. у додатку В. Помітимо, що змодельована змінна Притік має суттєво вищу кореляцію, ніж змінна на офіційних даних.

3 ПОБУДОВА МОДЕЛІ

Оскільки у нас наявна інформація про ціни на квартири для різних кількостей кімнат (1, 2 або 3), для кожного періоду побудуємо три окремі моделі, які в якості відгуку містять K1, K2 або K3, а також комбіновану модель, що містить змінну Кімнатність як категоріальну.

Врахуємо, що змінних із щоденними спостереженнями дуже мало, тому усе-реднимо їх до щомісячних.

3.1 Схеми побудови моделі

У літературі не існує єдиного загальноприйнятого алгоритму побудови регресійної моделі, оскільки вибір конкретних методів залежить від природи даних, мети дослідження та наявних обчислювальних ресурсів. У цій роботі ми дотримуємося наступної стратегії, яка складається із таких послідовних кроків:

1. **Аналіз кореляції між предикторами.** Перед побудовою моделі змінні, що сприяють сильній мультиколінеарності, підлягають вилученню або заміні на складені показники, наприклад, частку, добуток, середнє двох змінних. Такі складені змінні також називають **ефектами взаємодії**.
2. **Побудова повної моделі.** Будуємо модель, що включає всі відібрані предиктори. Це дає змогу отримати початкове уявлення про значимість предикторів і загальну якість моделі.
3. **Перевірка регресійних припущень.** За допомогою засобів, описаних у розділі 1.4, проводимо перевірку всіх поставлених регресійних припущень.
4. **Застосування функціональних перетворень.** Якщо діагностика виявляє порушення припущень або функціональні перетворення значно покращують модель, застосовуються трансформації відгуку або предикторів (див. підрозділ 1.5). Якщо модель було змінено, повертаємося до попереднього кроку.

5. **Перебір усіх можливих варіантів моделей.** Виконуємо повний перебір підмножин предикторів, тобто на виході отримаємо 2^{k_0} підмоделей, де k_0 — кількість предикторів моделі на поточному кроці. Відбираємо найкращі підмоделі за показниками R_{adj}^2 , BIC та C_p .
6. **Введення ефектів взаємодії.** Для найкращих моделей перевіряється доцільність додавання попарних добутоків та часток предикторів. Взаємодія залишається в моделі, якщо вона є статистично значущою та має економічну інтерпретацію.
7. **Валідація моделі.** Для фінальних моделей застосовуємо методи крос-валідації та обчислюємо R_{pred}^2 (див. підрозділ 1.6). Остаточний вибір моделі здійснюється з урахуванням як статистичних показників, так і логічності знаків коефіцієнтів.

Зауваження. Рішення про додавання того чи іншого ефекту взаємодії приймається на основі відбору найкращих пар взаємодій за критерієм AIC.

3.2 Побудова моделі для першого періоду

Предиктори, для яких після поділу набору даних кількість спостережень більша за 10, наведені в таблиці 3.

Таблиця 3 — Змінні першого періоду (01.01.2016–31.12.2021)

	Євро	Долар	K1	K2	K3	ІФС
К-сть спост.	72	72	72	72	72	72
Періодичність	місячна	місячна	місячна	місячна	місячна	місячна
	ІГР	РівДолар	ЧисНасел	ЧистГриКред	ІндМатСтан	ІЦЖВ
К-сть спост.	72	72	72	37	25	20
Періодичність	місячна	місячна	місячна	місячна	місячна	квартальна
	ІЦЖП	ТемпЗмінКошт				
К-сть спост.	20	13				
Періодичність	квартальна	квартальна				

Отже, спочатку будуюмо модель на 72 щомісячних спостереженнях.

Введемо в розгляд трендову змінну Ч, яка відповідає номеру спостереження (у цьому випадку — номеру місяця від початку 2016 року).

Дослідження на мультиколінеарність

Дослідимо зв'язки між предикторами. Побудуємо для відповідних предикторів кореляційну матрицю (рис. 2). Із матриці видно, що трендова змінна Ч сильно корелює відразу з двома іншими предикторами, тому вилучимо саме її, оскільки вона є штучною. Сильно корельованими залишаються Євро та Долар, проте перед тим, як приймати рішення про вилучення однієї з цих змінних, дослідимо показники VIF (табл. 4) та число обумовленості.

Таблиця 4 — Значення VIF для змінних першого періоду

	Євро	Долар	ІФС	ІГР	ІЦБ	ЧисНасел	РівДолар
VIF	6.1093	5.0459	1.5415	1.2277	1.6615	4.5929	3.7705

Показники Євро та Долар є трохи вищими за порогове значення в 5 одиниць, проте загальна картина із VIF є прийнятною, тому вважаємо, що серйозних проблем із мультиколінеарністю немає.




Рис. 2 — Кореляційна матриця предикторів для першого періоду

Число обумовленості матриці $X'X$:

$$\kappa = 18.0552.$$

У літературі традиційно вважається, що при $\kappa < 30$ мультиколінеарність є слабкою. Отже, даний набір змінних готовий до подальшого опрацювання. Зауважимо, що число обумовленості за замовчуванням обчислюється не для самої матриці регресорів $X'X$, а для матриці регресорів, нормованих за одиничною довжиною [17].

Звернімо увагу, що найсильніше з цінами корелюють змінні ЧисНасел і РівДолар. Це ознака того, що скоріш за все саме вони будуть найвпливовішими змінними на відгук у кінцевій моделі.

3.2.1 Модель на основі цін однокімнатних квартир

Повна модель має вигляд:

$$\hat{K}_1 = \hat{\beta}_0 + \hat{\beta}_1 \text{Євро} + \hat{\beta}_2 \text{Долар} + \hat{\beta}_3 \text{ІФС} + \hat{\beta}_4 \text{ІГР} + \hat{\beta}_5 \text{ІЦБ} + \hat{\beta}_6 \text{ЧисНасел} + \hat{\beta}_7 \text{РівДолар},$$

де оцінки коефіцієнтів $\hat{\beta}_j$ наведено в таблиці 5.

Таблиця 5 — Оцінки коефіцієнтів повної моделі

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.326×10^5	3.028×10^4	-4.379	4.50×10^{-5}
Євро	-3.903×10^2	1.090×10^2	-3.580	6.63×10^{-4}
Долар	5.104×10^2	1.881×10^2	2.714	8.54×10^{-3}
ІФС	2.696×10^3	2.242×10^3	1.202	2.336×10^{-1}
ІГР	-5.617×10^2	5.392×10^2	-1.042	3.015×10^{-1}
ІЦБ	3.852×10^1	1.918×10^1	2.008	4.88×10^{-2}
ЧисНасел	5.082×10^{-2}	9.681×10^{-3}	5.249	1.85×10^{-6}
РівДолар	-3.403×10^2	4.833×10^1	-7.041	1.58×10^{-9}

$RMSE = 804.1$; $R^2 = 0.872$; $R_{adj}^2 = 0.858$; $F = 62.27$; $p\text{-value} < 2.2 \times 10^{-16}$. Тут і далі $RMSE = \sqrt{MS_{Res}}$.

У повній моделі змінні ІФС та ІГР не пройшли тест на статистичну значущість. Це свідчить про те, що скоріш за все вони не будуть включені до фінальної моделі.

Проаналізуємо діаграму розкиду залишків повної моделі (рис. 3). Явних патернів на діаграмі не видно, проте незначне порушення лінійності можливе. Можливо, наявна незначна гетероскедастичність. Зобразимо також діаграму розкиду залишків для кожного предиктора окремо (рис. 4). Діаграми для змінних Євро, Долар, ІЦБ, РівДолар виглядають задовільно. ІФС, ІГР — наявні кілька екстремальних значень, які спотворюють графік. Це було спричинено різким зростанням цих показників у кінці 2021 року. Можливо, саме через це ІФС та ІГР не є статистично значущими у повній моделі (такі екстремальні значення ”зіпсували” зв’язок із ціною). На графіку ЧисНасел також не видно очевидних порушень. Так, для цієї діаграми характерною є неоднорідність точок. Вона зумовлена особливістю даних про ЧисНасел (див. рис. 1): показник зростає дещо стрибкоподібно, особливо




Рис. 3 — Діаграма розсіювання залишків повної моделі

на початку.

На графіках доданої змінної та на `crPlots` видно потенційну проблему зі змінними ІФС та ІГР (див. додаток А, рис. 13). На графіках доданої змінної побудовані прямі для цих змінних погано описують тенденцію. На графіках `crPlots` хоч LOESS-пряма і незначно відхиляється від регресійної, проте це є наслідком наявності екстремальних значень у даних, а не ознакою того, що предиктори мають хорошу пояснювальну силу для Ціни.

Провдемо статистичні тести:

- Тест RESET: $F = 2.40$, $df_1 = 1$, $df_2 = 63$, $p = 0.126$ — лінійна форма не відхиляється.
- Тест Бройша–Пагана: $BP = 9.88$, $df = 7$, $p = 0.196$ — гомоскедастичність не відхиляється.

Зауважимо, що тут і далі в дослідженні ми використовуємо RESET-test для перевірки значимості квадратичних членів моделі, тобто RESET-test, описаний в п.п. 1.4.1, при $\gamma_2 = 0$.

Оскільки модель не має очевидних порушень, то функціональне перетворення застосуємо на основі покращення показників якості. Застосуємо метод Бокса-




Рис. 4 — Діаграми розсіювання залишків для всіх предикторів

Кокса: $\lambda_{opt} = -0.02 \approx 0$ — рекомендовано трансформацію $\ln(\text{Ціна})$, оскільки 1 не потрапляє в довірчий інтервал λ_{opt} . Отже, далі працюємо із моделлю, що містить $\ln(\text{Ціна})$ в якості відгуку.

Задля скорочення викладок пропустимо кілька ітерацій побудови моделі, а саме — перевірку адекватності нової (трансформованої) моделі.

Після застосування всіх функціональних перетворень отримуємо модель із $\ln(\text{Ціна})$ та наступними коефіцієнтами (табл. 6).

Таблиця 6 — Оцінки коефіцієнтів моделі з квадратичним членом

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.334	6.979	0.764	4.476×10^{-1}
Євро	-5.290×10^{-2}	1.284×10^{-2}	-4.119	1.130×10^{-4}
Долар	-1.073×10^0	3.992×10^{-1}	-2.689	9.166×10^{-3}
ІФС	6.082×10^{-2}	2.604×10^{-1}	0.234	8.161×10^{-1}
ІГР	-1.186×10^{-1}	6.200×10^{-2}	-1.913	6.030×10^{-2}
ЦБ	6.915×10^{-3}	2.221×10^{-3}	3.114	2.776×10^{-3}
ЧисНасел	6.587×10^{-6}	1.141×10^{-6}	5.774	2.560×10^{-7}
РівДолар	-4.133×10^{-2}	5.592×10^{-3}	-7.390	4.160×10^{-10}
Долар ²	2.181×10^{-2}	7.672×10^{-3}	2.843	6.023×10^{-3}

$$RMSE = 0.09203; R^2 = 0.9011; R_{adj}^2 = 0.8885; F = 71.72; p\text{-value} < 2.2 \times 10^{-16}.$$

Звернімо увагу, що незначущість ІФС стала ще більш відчутною.




Рис. 5 — Q-Q Plot для лог-моделі з квадратичним членом

Q-Q Plot для цієї моделі виглядає цілком адекватно (рис. 5). Відхилення точок від теоретичної прямої не є достатньо значним, щоб не вважати розподіл нормальним.

Проведемо перевірку гіпотез:

- Тест Шапіро–Вілка: $W = 0.988$, $p = 0.699$ — нормальність залишків не відхиляється.
- Тест Дарбіна–Уотсона: $DW = 0.807$, $p < 0.001$ — наявна значна додатня автокореляція.

Отже, в даних наявні серйозні проблеми з автокореляцією, тому надалі для моделі використовуємо НАС-стандартні помилки оцінок.

Після перебору всіх можливих підмоделей та ефектів взаємодій і вилучення статистичну незначущих предикторів, отримуємо такі найкращі моделі з їх показниками валідації (для k-fold $k = 5$, для forward chaining горизонт рівний

одиниці):

Таблиця 7 — Оцінки коефіцієнтів найкращих підмоделей для K1

Модель 1: $\ln(\text{Ціна}) \sim \text{ЧисНасел} + \text{РівДолар}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-9.437	3.746	-2.519	1.410×10^{-2}
ЧисНасел	6.752×10^{-6}	1.204×10^{-6}	5.608	3.921×10^{-7}
РівДолар	-3.350×10^{-2}	6.076×10^{-3}	-5.513	5.712×10^{-7}

$R^2 = 0.862$; $R^2_{adj} = 0.858$; $AIC = -117.0$; $BIC = -107.9$; $C_p = 21.7$; Pred. $R^2 = 0.847$; 5-fold $R^2 = 0.863$;
 $RMSE_{train} = 0.102$; $RMSE_{FC} = 0.076$.

Модель 2: $\ln(\text{Ціна}) \sim \text{Євро} + \text{Долар} + \text{ІПР} + \text{ІЦБ} + \text{ЧисНасел} + \text{РівДолар} + \text{Долар}^2$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.886	7.853	0.750	0.456
Євро	-5.337×10^{-2}	2.203×10^{-2}	-2.423	0.018
Долар	-1.089	0.551	-1.976	0.052
ІПР	-0.121	0.051	-2.390	0.020
ІЦБ	6.909×10^{-3}	3.141×10^{-3}	2.200	0.031
ЧисНасел	6.476×10^{-6}	9.683×10^{-7}	6.688	< 0.001
РівДолар	-4.154×10^{-2}	4.730×10^{-3}	-8.783	< 0.001
Долар ²	2.211×10^{-2}	1.085×10^{-2}	2.038	0.046

$R^2 = 0.901$; $R^2_{adj} = 0.890$; $AIC = -130.8$; $BIC = -110.3$; $C_p = 7.05$; Pred. $R^2 = 0.862$; 5-fold $R^2 = 0.888$;
 $RMSE_{train} = 0.086$; $RMSE_{FC} = 0.079$.

Модель 3: $\ln(\text{Ціна}) \sim \text{Модель 2} + \text{Долар/Євро}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	27.720	12.532	2.212	0.031
Євро	-0.499	0.136	-3.679	< 0.001
Долар	-1.060	0.480	-2.210	0.031
ІПР	-0.117	0.044	-2.638	0.011
ІЦБ	5.465×10^{-3}	2.232×10^{-3}	2.449	0.017
ЧисНасел	5.943×10^{-6}	9.910×10^{-7}	5.997	< 0.001
РівДолар	-4.163×10^{-2}	3.717×10^{-3}	-11.200	< 0.001
Долар ²	3.129×10^{-2}	1.164×10^{-2}	2.689	0.009
Долар/Євро	-15.760	4.680	-3.367	0.001

$R^2 = 0.911$; $R^2_{adj} = 0.899$; $AIC = -136.2$; $BIC = -113.4$; $C_p = 2.87$; Pred. $R^2 = 0.873$; 5-fold $R^2 = 0.881$;
 $RMSE_{train} = 0.082$; $RMSE_{FC} = 0.070$.

Не завжди очевидно, яка з моделей є кращою. Наприклад, модель 2 є простішою за модель 3, оскільки містить на одну змінну менше. Проте модель 3 не має проблем зі статистичною значущістю (в моделі 2 значущість Долара знаходиться на межі). Або ж модель 1 явно «програє» іншим моделям по статистичних показниках, проте на відміну від них вона містить всього дві змінні, при цьому все ще маючи цілком пристойні показники. Якщо ж брати до уваги тільки цифри, то найкращою з моделей є модель 3.

Зобразимо діаграми розсіювання залишків проти відгуку та проти кожного з регресорів окремо для Моделі 3 (рис. 6). Як бачимо, графіки стали ближчими до ідеалу: відсутність патернів, сталий розкид, проте неоднорідність точок повні-

стю не виправилась. Отже, фінальна модель є адекватною (за умови використання робастних до автокореляції оцінок).




Рис. 6 — Діаграми розсіювання залишків проти відгуку та проти кожного з регресорів окремо для Моделі 3

Введення ЧистГрнКред у модель

Введемо до розгляду змінну, що звужує вибірку до 37 спостережень — ЧистГрнКред. Зобразимо розширену кореляційну матрицю що міститиме також ЧистГрнКред (рис. 7). Перша суттєва зміна після звуження вибірки — це те, що кореляція між курсами валют стала сильнішою, Євро та Долар тепер фактично дублюють один одного. Нова змінна ЧистГрнКред сильну корелює з РівДолар та Ч. Якщо Ч — це штучна змінна, яку не шкода вилучити, то РівДолар, як ми бачили раніше, — одна з ключових змінних моделі. Хоча з іншого боку, ЧистГрнКред сильніше корелює із цінами. Проте звуження вибірки у два рази та вилучення інших змінних, які виявилися значущими раніше, із моделі не варте того, щоб у моделі з'явилася змінна, яка корелює з цінами найсильніше.




Рис. 7 — Розширена кореляційна матриця предикторів для першого періоду

Введення ІндМатСтан у модель

Спробуймо ввести ІндМатСтан у модель. Кореляційна матриця предикторів зображена на рис. 8. Тут ситуація інакша, але все ще погана: ІндМатСтан корелює лише з предикторами, але проблема в тому, що в межах деякого короткого періоду багато змінних, розглянутих раніше, виявились сильно корельованими. Отже, в нашому випадку звуження вибірки до коротшого періоду підсилює ефект мультиколінеарності.




Рис. 8 — Розширена кореляційна матриця предикторів для першого періоду

Введення ІЦЖП, ІЦЖВ у модель

Крім звуження періоду можна також розглянути усереднення — в цьому випадку усереднення до квартальних даних. Зробивши таке усереднення, можемо тепер розглянути змінні ІЦЖП та ІЦЖВ на вибірці з 20 спостережень. Кореляційна матриця предикторів зображена на рисунку 9. Відмітимо, що обидві нові змінні сильно корелюють із РівДолар і між собою. Тому спробуємо вилучити РівДолар і трендову змінну Ч.




Рис. 9 — Розширена кореляційна матриця предикторів для першого періоду

Розглянемо фактори інфляції дисперсії для цього набору змінних (таблиця 8).

Таблиця 8 — Значення VIF для розширеного набору змінних другого періоду

	Євро	Долар	ІФС	ІГР	ІЦБ	ЧисНасел	ІЦЖВ	ІЦЖП
VIF	12.897	5.876	2.473	3.042	3.194	4.054	13.466	17.704

Як бачимо, нові змінні мають незадовільні показники VIF. Це є результатом сильної кореляції між ІЦЖП та ІЦЖВ, а також кореляції цих змінних із ЧисНасел. Замість пари змінних ІЦЖП, ІЦЖВ відношення ІЦЖП/ІЦЖВ (таблиця. 9).

Таблиця 9 — Значення VIF після заміни введення взаємодії

	Євро	Долар	ІФС	ІГР	ІЦБ	ЧисНасел	ІЦЖП/ІЦЖВ
VIF	6.326	4.208	1.624	1.153	3.188	3.816	3.294

Отже, введення ефекту взаємодії дійсно виправило проблему з мультиколінеарністю. Число обумовленості також низьке:

$$\kappa = 12.3201.$$

Цього разу при переборі підмоделей відбиратимемо тільки ті, що містять ІЦЖП/ІЦЖВ, бо інакше усереднення даних та зменшення об'єму вибірки не матиме сенсу. У результаті отримаємо одну модель (таблиця 10). В алгоритмі forward chaining об'єм початкової вибірки — 12.

Таблиця 10 — Оцінки коефіцієнтів моделі на розширеному наборі змінних - K1

Модель: Ціна $\sim$ ІЦБ + ЧисНасел + ІЦЖП/ІЦЖВ

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.111×10^5	4.821×10^4	-6.451	< 0.001
ІЦБ	1.599×10^2	4.755×10^1	3.364	0.004
ЧисНасел	1.151×10^{-1}	1.335×10^{-2}	8.618	< 0.001
ІЦЖП/ІЦЖВ	-3.792×10^4	1.430×10^4	-2.652	0.017

$$R^2 = 0.833; R^2_{adj} = 0.802; AIC = 329.6; BIC = 334.5.$$

Враховуючи, що тепер вибірка містить лише 20 спостережень, ця модель є помітно гіршою за ті, моделі, що були отримані раніше на основі місячних даних. Проте перевіримо, чи буде така модель кращою для одно- чи двокімнатних квартир.

Оскільки модель на 20 спостереженнях не має більше пояснювальної сили за початкову модель, то звужувати вибірку далі немає сенсу. Отже, змінну ТемпЗмінКошт (13 спостережень) не розглядаємо.

3.2.2 Модель на основі цін двокімнатних квартир

За аналогічними міркуваннями, взявши в якості відгуку ціни на оренду двокімнатних квартир, отримані найкращі моделі матимуть вигляд, як у таблиці 11. Тут логарифмічне перетворення також було запропоноване методом Бокса–Кокса.

У цьому випадку виникає та ж дилема, що і для моделі на основі K1. Якщо при порівнянні моделей не враховувати складність, то кращою є модель 1. Хоча з іншого боку — вона не є набагато складнішою.

Варто зазначити, що всі найкращі моделі, отримані на основі K1, мали кращі показники якості, ніж у цьому випадку. Хоча в той же час моделі для однокімнатних квартир є складнішими, оскільки містять на один квадратичний член більше.

Таблиця 11 — Оцінки коефіцієнтів найкращих підмоделей для K2**Модель 1:** $\ln(\text{Ціна}) \sim \text{Євро} + \text{Долар} + \text{ІГР} + \text{ІЦБ} + \text{ЧисНасел} + \text{РівДолар} + \text{Долар}^2 + \text{Євро}^2$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	22.261	12.547	1.774	0.081
Євро	0.662	0.301	2.198	0.032
Долар	-2.490	1.150	-2.167	0.034
ІГР	-0.094	0.038	-2.493	0.015
ІЦБ	6.312×10^{-3}	2.487×10^{-3}	2.538	0.014
ЧисНасел	3.632×10^{-6}	1.188×10^{-6}	3.057	0.003
РівДолар	-3.960×10^{-2}	5.445×10^{-3}	-7.273	< 0.001
Долар ²	4.832×10^{-2}	2.207×10^{-2}	2.189	0.032
Євро ²	-1.157×10^{-2}	4.913×10^{-3}	-2.354	0.022

$R^2 = 0.851$; $R^2_{adj} = 0.832$; $AIC = -127.2$; $BIC = -104.4$; $\text{Pred. } R^2 = 0.800$; 5-fold $R^2 = 0.805$; $\text{RMSE}_{train} = 0.087$;
 $\text{RMSE}_{FC} = 0.078$.

Модель 2: $\ln(\text{Ціна}) \sim \text{Модель 1 без ІГР}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	20.649	13.199	1.564	0.123
Євро	0.661	0.314	2.107	0.039
Долар	-2.441	1.229	-1.986	0.051
ІЦБ	5.707×10^{-3}	2.415×10^{-3}	2.363	0.021
ЧисНасел	3.947×10^{-6}	1.105×10^{-6}	3.571	< 0.001
РівДолар	-3.671×10^{-2}	4.263×10^{-3}	-8.613	< 0.001
Долар ²	4.724×10^{-2}	2.361×10^{-2}	2.001	0.050
Євро ²	-1.147×10^{-2}	5.144×10^{-3}	-2.229	0.029

$R^2 = 0.845$; $R^2_{adj} = 0.828$; $AIC = -126.6$; $BIC = -106.1$; $\text{Pred. } R^2 = 0.802$; 5-fold $R^2 = 0.829$; $\text{RMSE}_{train} = 0.089$;
 $\text{RMSE}_{FC} = 0.066$.

Введення ІЦЖП, ІЦЖВ у модель

Використовуючи все ще той самий алгоритм, отримаємо таку ж модель, як і для однокімнатних квартир (таблиця 12).

Таблиця 12 — Оцінки коефіцієнтів моделі на розширеному наборі змінних — K2**Модель:** $\text{Ціна} \sim \text{ІЦБ} + \text{ЧисНасел} + \text{ІЦЖП/ІЦЖВ}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.554×10^5	8.480×10^4	-4.191	< 0.001
ІЦБ	2.514×10^2	7.107×10^1	3.538	0.003
ЧисНасел	1.325×10^{-1}	2.303×10^{-2}	5.751	< 0.001
ІЦЖП/ІЦЖВ	-5.218×10^4	2.340×10^4	-2.231	0.040

$R^2 = 0.737$; $R^2_{adj} = 0.688$; $AIC = 346.8$; $BIC = 351.8$; $\text{Pred. } R^2 = 0.588$; 5-fold $R^2 = 0.773$; $\text{RMSE}_{train} = 1099.0$;
 $\text{RMSE}_{FC} = 1240.7$.

Ця модель є поганою: по-перше, її показник R^2_{adj} є досить низьким; по-друге, модель має незадовільні показники валідації, зокрема R^2_{pred} , який є меншим за R^2_{adj} на 0.1. Це означає, що модель погано узагальнюється на нові дані.

3.2.3 Модель на основі цін трикімнатних квартир

Найкраща модель на основі 3-кімнатних квартир — одна (таблиця 13). У цьому випадку методом Бокса–Кокса було отримано $\lambda_{opt} = -1.84$, проте довірчий інтервал містить також значення -1 , тому щоб не ускладнювати модель та інтерпретацію результатів, візьмемо $\lambda = -1$.

Таблиця 13 — Оцінки коефіцієнтів фінальної моделі для КЗ

Модель: $1/\text{Ціна} \sim \text{Євро} + \text{ЩБ} + \text{ЧисНасел} + \text{РівДолар} + \ln(\text{РівДолар}) + \text{Долар}^2 + \text{Євро}^2 + \text{Євро} \times \text{Долар}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.685×10^{-3}	4.159×10^{-4}	-4.051	< 0.001
Євро	3.550×10^{-5}	1.064×10^{-5}	3.336	0.001
ЩБ	-6.223×10^{-7}	1.210×10^{-7}	-5.144	< 0.001
ЧисНасел	-2.973×10^{-10}	4.946×10^{-11}	-6.011	< 0.001
РівДолар	-1.738×10^{-5}	3.320×10^{-6}	-5.234	< 0.001
$\ln(\text{РівДолар})$	7.756×10^{-4}	1.367×10^{-4}	5.674	< 0.001
Долар ²	3.094×10^{-6}	4.357×10^{-7}	7.101	< 0.001
Євро ²	1.873×10^{-6}	2.482×10^{-7}	7.547	< 0.001
Євро $\times$ Долар	-5.532×10^{-6}	7.850×10^{-7}	-7.046	< 0.001

$R^2 = 0.838$; $R^2_{adj} = 0.818$; $AIC = -1563.3$; $BIC = -1540.5$; $\text{Pred. } R^2 = 0.792$; 5-fold $R^2 = 0.798$;
 $\text{RMSE}_{train} = 4.06 \times 10^{-6}$; $\text{RMSE}_{FC} = 3.62 \times 10^{-6}$.

Введення ЩЖП, ЩЖВ у модель

Результатом є модель у таблиці 14.

Таблиця 14 — Оцінки коефіцієнтів моделі на розширеному наборі змінних — КЗ

Модель: $\text{Ціна} \sim \text{ІГР} + \text{ЩБ} + \text{ЧисНасел} + \text{ЩЖП/ЩЖВ}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.028×10^5	9.540×10^4	-3.174	0.006
ІГР	8.116×10^3	3.380×10^3	2.401	0.030
ЩБ	2.697×10^2	9.646×10^1	2.796	0.014
ЧисНасел	1.176×10^{-1}	2.795×10^{-2}	4.209	< 0.001
ЩЖП/ЩЖВ	-6.078×10^4	2.152×10^4	-2.825	0.013

$R^2 = 0.642$; $R^2_{adj} = 0.547$; $AIC = 364.9$; $BIC = 370.8$; $\text{Pred. } R^2 = 0.248$; 5-fold $R^2 = 0.514$; $\text{RMSE}_{train} = 1640.5$;
 $\text{RMSE}_{FC} = 2354.3$.

Модель є геть неадекватною. Результати валідації вкрай низькі. Результати такої моделі використовувати не можна.

3.2.4 Комбінована модель

Нарешті будуємо модель, яка об'єднує всі три попередні моделі в одну, тобто таку, яка містить змінну Кімнатність (кількість кімнат) як категоріальну з трьома рівнями (одно-, дво-, та трикімнатні квартири). Особливістю такого підходу є те, що для побудови регресійної моделі дані потрібно привести до панельних. У свою чергу панельність даних створює залежність між спостереженнями, оскільки тепер на кожне спостереження припадає три рядки, які різняться тільки ціною оренди. Тобто по суті, спостереження за одну і ту ж дату є майже однаковими, що створює ще більші проблеми з автокореляцією. Також у панельних даних з'являється поняття **міжгрупового розкиду залишків**. Інакше кажучи, для того, щоб задовільнити припущення про гомоскедастичність, необхідно також враховувати, щоб дисперсія похибок була однаковою для всіх груп (кімнат). Для перевірки міжгрупової гомоскедастичності існують спеціальні тести, призначені для панельних даних. Проте оскільки наші дані мають значні проблеми з автокореляцією, то ми і далі будемо використовувати робастні до стандартні помилки — які враховують як автокореляцію, так і гетероскедастичність — лише за тієї відмінності, що зараз використовуватимемо Driscoll-Kraay (DK)-помилки, які враховують панельність даних [13].

З іншого боку, панельні дані розширюють ефективний розмір вибірки, і стандартні оцінені коефіцієнти мають бути стабільнішими.

Найкращі моделі див. у таблиці 15. У цьому випадку $\lambda_{opt} = 0.41$, тому візьмемо $\lambda = 0.5$.

Таблиця 15 — Оцінки коефіцієнтів фінальних моделей (комбінована вибірка)**Модель 1:** $\sqrt{\text{Ціна}} \sim \text{Євро} + \text{Долар} + \text{ІЦБ} + \text{Кімнатність} + \ln(\text{РівДолар}) + \ln(\text{Євро}) + \text{Долар}^2 + \text{Долар} \times \text{ІЦБ}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	246.215	563.125	0.437	0.662
Євро	-39.121	10.879	-3.596	< 0.001
Долар	-145.155	35.039	-4.143	< 0.001
ІЦБ	-10.019	2.578	-3.887	< 0.001
Кімнатність2	15.802	0.398	39.725	< 0.001
Кімнатність3	34.333	1.141	30.102	< 0.001
$\ln(\text{РівДолар})$	-111.331	5.726	-19.444	< 0.001
$\ln(\text{Євро})$	1136.731	333.440	3.409	< 0.001
Долар^2	2.018	0.675	2.989	0.003
$\text{Долар} \times \text{ІЦБ}$	0.378	0.096	3.938	< 0.001

$R^2 = 0.928$; $R^2_{adj} = 0.924$; $AIC = 1320.5$; $BIC = 1357.6$; $\text{Pred. } R^2 = 0.920$; 5-fold $R^2 = 0.923$; $\text{RMSE}_{train} = 4.888$; $\text{RMSE}_{FC} = 4.666$.

Модель 2: $\sqrt{\text{Ціна}} \sim \text{ЧисНасел} + \text{Кімнатність} + \text{РівДолар} + \text{ЧисНасел} \times \text{Кімнатність}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-521.552	247.751	-2.105	0.036
ЧисНасел	2.349×10^{-4}	7.722×10^{-5}	3.042	0.003
Кімнатність2	160.653	41.118	3.907	< 0.001
Кімнатність3	624.934	103.704	6.027	< 0.001
РівДолар	-1.844	0.524	-3.517	< 0.001
$\text{ЧисНасел} \times \text{Кімнатність2}$	-4.925×10^{-5}	1.406×10^{-5}	-3.504	< 0.001
$\text{ЧисНасел} \times \text{Кімнатність3}$	-2.008×10^{-4}	3.551×10^{-5}	-5.654	< 0.001

$R^2 = 0.894$; $R^2_{adj} = 0.891$; $AIC = 1397.2$; $BIC = 1424.2$; $\text{Pred. } R^2 = 0.887$; 5-fold $R^2 = 0.898$; $\text{RMSE}_{train} = 5.919$; $\text{RMSE}_{FC} = 5.035$.

Важливо, щоб медіана, зображена на коробкових діаграмах для категорій (див. рисунок 10), знаходилась на нульовому рівні. Відхилення вгору (вниз) від нуля медіани для категорії К означає, що модель систематично переоцінює (недооцінює) значення відгуку для категорії К. Отже, найкращі підмоделі порівнювалися і за величиною цього відхилення.




Рис. 10 — Діаграми розсіювання залишків для кожного регресора Моделі 1

Введення ІЦЖП, ІЦЖВ у модель

Результат наведений у таблиці 16.

Таблиця 16 — Оцінки коефіцієнтів моделі на розширеному наборі змінних

Модель: $\sqrt{\text{Ціна}} \sim \text{Євро} + \text{Долар} + \text{ІЦБ} + \text{ЧисНасел} + \text{ІЦЖВ} + \text{Кімнатність} + \ln(\text{Долар}) + \ln(\text{Євро})$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7353.852	2178.442	3.376	0.003
Євро	-55.905	15.189	-3.680	0.002
Долар	205.632	42.480	4.841	< 0.001
ІЦБ	0.852	0.109	7.789	< 0.001
ЧисНасел	2.400×10^{-4}	8.800×10^{-5}	2.733	0.013
ІЦЖВ	1.905	0.245	7.774	< 0.001
Кімнатність2	15.479	0.677	22.863	< 0.001
Кімнатність3	32.832	1.910	17.186	< 0.001
$\ln(\text{Долар})$	-5391.809	1108.002	-4.866	< 0.001
$\ln(\text{Євро})$	1654.276	471.275	3.510	0.002

$R^2_{adj} = 0.938$; $\text{RMSE}_{train} = 3.823$; $\text{Pred. } R^2 = 0.927$; 5-fold $R^2 = 0.953$; $\text{RMSE}_{FC} = 7.003$.

За всіма показниками модель із ІЦЖВ є кращою за модель на щомісячних даних. Проте її оцінки можуть бути менш стабільними через те, що вона має меншу кількість спостережень (60 замість 216).

3.2.5 Використання змодельованої змінної

Використаймо змодельовану змінну Притік із підрозділу 2.2. Кореляційну матрицю набору змінних разом зі змінною Притік див. у додатку В (рис. 16). Результати наведено в таблиці 17.

Таблиця 17 — Оцінки коефіцієнтів фінальної моделі зі змодельованим притоком

$$\sqrt{\text{Ціна}} \sim \text{ЧисНасел} + \text{РівДолар} + \text{Притік} + \text{Кімнатність} + \ln(\text{РівДолар}) + \text{РівДолар}^2 + \text{ЧисНасел} \times \text{Кімнатність}$$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.661×10^4	3.960×10^3	4.195	< 0.001
ЧисНасел	2.137×10^{-4}	5.086×10^{-5}	4.203	< 0.001
РівДолар	3.326×10^2	8.319×10^1	3.998	< 0.001
Притік	7.418×10^{-4}	1.020×10^{-4}	7.272	< 0.001
Кімнатність2	1.607×10^2	3.852×10^1	4.171	< 0.001
Кімнатність3	6.249×10^2	9.596×10^1	6.512	< 0.001
$\ln(\text{РівДолар})$	-7.462×10^3	1.771×10^3	-4.213	< 0.001
РівДолар^2	-1.845	0.485	-3.808	< 0.001
$\text{ЧисНасел} \times \text{Кімнатність2}$	-4.925×10^{-5}	1.315×10^{-5}	-3.744	< 0.001
$\text{ЧисНасел} \times \text{Кімнатність3}$	-2.008×10^{-4}	3.279×10^{-5}	-6.125	< 0.001

$R^2 = 0.951$; $R^2_{adj} = 0.948$; $AIC = 1238.0$; $BIC = 1275.2$; $\text{Pred. } R^2 = 0.945$; 5-fold $R^2 = 0.946$; $\text{RMSE}_{train} = 4.039$; $\text{RMSE}_{FC} = 3.642$.

Як бачимо, змодельована змінна Притік є високозначущим предиктором для Ціни. Помітимо, що ця модель має дещо вищий коефіцієнт детермінації за модель, побудовану лише на офіційних даних.

3.3 Побудова моделі для другого періоду

Після поділу даних отримуємо такі змінні (таблиця 18):

Таблиця 18 — Змінні другого періоду (01.01.2022–01.01.2026)

	Євро	Долар	K1	K2	K3	ІФС
К-сть спост.	54	53	53	53	53	47
Періодичність	місячна	місячна	місячна	місячна	місячна	місячна
	ІГР	РівДолар	ІндМатСтан	ЧистГрнКред	ІЦБ	ІЦЖП
К-сть спост.	53	47	47	48	46	46
Періодичність	місячна	місячна	місячна	місячна	місячна	місячна
	ІЦЖВ	ТемпЗмінКошт				
К-сть спост.	46	22				
Періодичність	місячна	місячна				

Решта змінних випадає через недостатню кількість спостережень. Звернімо увагу, що всі наявні змінні мають щомісячні спостереження. Отже, спочатку розглядаємо весь набір змінних, крім ТемпЗмінКошт (46 спостережень).




Рис. 11 — Кореляційна матриця предикторів другого періоду

Дослідження на мультиколінеарність

Кореляційна матриця цього набору предикторів зображена на рисунку 11.

На основі кореляційної матриці в першу чергу вилучимо трендову змінну Ч, оскільки вона є штучною. Змінні ІЦЖП та ІЦЖВ є сильнокорельованими, тому залишимо одну з них — ІЦЖВ. Замість змінних Євро та Долар розглянемо відношення Євро/Долар. У результаті ми позбудемося сильних лінійних зв'язків між предикторами (див. рисунок 12).

Число обумовленості:

$$\kappa = 51.5648.$$

Таблиця 19 — Значення VIF для змінних другого періоду (розширений набір)

	ІФС	ІГР	ІЦБ	ІЦЖП	ІндМатСтан	РівДолар	ЧистГрнКред	Євро/Долар
VIF	4.647	8.587	10.724	5.789	4.219	3.108	7.138	2.500

Число обумовленості та показники VIF (таблиця 19) не є низькими, проте і сказати, що для множини предикторів характерна серйозна мультиколінеарність теж




Рис. 12 — Звужена кореляційна матриця предикторів другого періоду

не можна. Можливо, при подальшому відборі змінних буде вилучено предиктори, які мають найсильніший зв'язок з іншими предикторами, і жодних проблем із мультиколінеарністю не буде.

3.3.1 Модель на основі цін однокімнатних квартир

Найкраща модель наведена в таблиці 20.

Таблиця 20 — Оцінки коефіцієнтів моделі для другого періоду — K1

Модель: Ціна $\sim$ ІФС + ІндМатСтан + ЧистГрнКред + Євро/Долар

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.629×10^4	5.625×10^3	2.895	0.006
ІФС	-4.991×10^3	1.539×10^3	-3.243	0.002
ІндМатСтан	1.340×10^2	2.961×10^1	4.525	< 0.001
ЧистГрнКред	3.403×10^{-7}	2.715×10^{-8}	12.533	< 0.001
Євро/Долар	-1.478×10^4	5.967×10^3	-2.476	0.017

$R^2 = 0.919$; $R_{adj}^2 = 0.911$; $AIC = 780.1$; $BIC = 791.1$; $Pred. R^2 = 0.892$; 5-fold $R^2 = 0.911$; $RMSE_{train} = 1022.3$; $RMSE_{FC} = 1178.8$.

Звернімо увагу, що модель не містить жодних функціональних перетворень та ефектів взаємодій (крім введеного співвідношення валют на початку) та при цьому має дуже високі показники.

Введення ТемпЗмінКошт

ТемпЗмінКошт звужує вибірку до 22 щомісячних спостережень. Отримані найкращі моделі з ТемпЗмінКошт поступаються найкращій моделі по повній вибірці без цієї змінної (див. таблицю 24, додаток Б). Отже, ТемпЗмінКошт не включаємо в модель.

3.3.2 Модель на основі цін двокімнатних квартир

Результати див. у таблиці 21.

Таблиця 21 — Оцінки коефіцієнтів моделі для другого періоду — К2

Модель: $\ln(\text{Ціна}) \sim \text{ІндМатСтан} + \text{ЧистГрнКред} + \text{ІндМатСтан} \times \text{ЧистГрнКред}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.956	0.185	42.945	< 0.001
ІндМатСтан	2.348×10^{-2}	3.641×10^{-3}	6.448	< 0.001
ЧистГрнКред	8.454×10^{-11}	1.088×10^{-11}	7.771	< 0.001
ІндМатСтан $\times$ ЧистГрнКред	-1.112×10^{-12}	1.985×10^{-13}	-5.602	< 0.001

$$R^2 = 0.900; R_{adj}^2 = 0.893; AIC = -85.1; BIC = -76.0.$$

3.3.3 Модель на основі цін трикімнатних квартир

Найкращу модель див. у таблиці 22.

Таблиця 22 — Оцінки коефіцієнтів фінальної моделі для другого періоду — К3

Модель: $\ln(\text{Ціна}) \sim \text{ІФС} + \text{ІЦЖП} + \text{ІндМатСтан} + \text{ЧистГрнКред} + \text{Євро/Долар} + \text{ІЦЖП} \times \text{ІндМатСтан}$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.563	0.796	9.497	< 0.001
ІФС	-0.795	0.150	-5.301	< 0.001
ІЦЖП	2.060	0.414	4.976	< 0.001
ІндМатСтан	8.730×10^{-2}	1.442×10^{-2}	6.054	< 0.001
ЧистГрнКред	3.846×10^{-11}	2.781×10^{-12}	13.829	< 0.001
Євро/Долар	-1.866	0.456	-4.095	< 0.001
ІЦЖП $\times$ ІндМатСтан	-4.725×10^{-2}	9.393×10^{-3}	-5.030	< 0.001

$$R^2 = 0.932; R_{adj}^2 = 0.922; AIC = -86.8; BIC = -72.2.$$

3.3.4 Комбінована модель

Результати наведені в таблиці 23.

Таблиця 23 — Оцінки коефіцієнтів комбінованої моделі для другого періоду

Модель:
 $\ln(\text{Ціна}) \sim \text{ІФС} + \text{ІндМатСтан} + \text{РівДолар} + \text{Кімнатність} + \ln(\text{ЧистГрнКред}) + \text{ІндМатСтан} \times \ln(\text{ЧистГрнКред})$

Змінна	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-25.029	7.529	-3.324	0.001
ІФС	-0.310	0.118	-2.631	0.010
ІндМатСтан	0.366	0.141	2.603	0.010
РівДолар	2.265	0.793	2.856	0.005
Кімнатність2	0.262	0.014	18.297	< 0.001
Кімнатність3	0.589	0.019	31.104	< 0.001
$\ln(\text{ЧистГрнКред})$	1.422	0.321	4.430	< 0.001
$\text{ІндМатСтан} \times \ln(\text{ЧистГрнКред})$	-1.535×10^{-2}	6.010×10^{-3}	-2.554	0.012

$R^2 = 0.946$; $R^2_{adj} = 0.943$; $AIC = -264.6$; $BIC = -238.2$; $\text{Pred. } R^2 = 0.940$; 5-fold $R^2 = 0.945$; $\text{RMSE}_{train} = 0.087$; $\text{RMSE}_{FC} = 0.085$.

ВИСНОВКИ

У даній кваліфікаційній роботі було поставлено та виконано задачу побудови моделей множинної лінійної регресії для прогнозування цін оренди житла в Києві залежно від обраних макроекономічних і соціальних факторів впливу. Для цього було зібрано широку вибірку статистичних даних та проведено їх ретельний попередній аналіз.

У роботі реалізовано повний цикл побудови регресійних моделей: від попереднього аналізу кореляцій та перевірки мультиколінеарності до крос-валідації фінальних моделей. Побудовано окремі моделі для одно-, дво- та трикімнатних квартир, а також комбіновану модель із категоріальною змінною «Кімнатність». Досліджено ефекти взаємодії між предикторами, що дозволило виявити нелінійні ефекти.

Отримані моделі демонструють високу якість: скоригований коефіцієнт детермінації R_{adj}^2 для фінальних моделей становить 0.89–0.95, прогностичний — R_{pred}^2 — приблизно йому відповідає. Методами крос-валідації підтверджено стійкість моделей та відсутність перенавчання.

Окремим результатом роботи є стохастичне моделювання динаміки чисельності населення Києва. Побудовано динамічну модель міграції, параметри якої відкалібровано за довоєнними даними (2016–2021 рр.). Отримані оцінки притоку узгоджуються з реальними демографічними тенденціями. Включення змодельованого притоку до регресійної моделі дозволило покращити її прогностичну здатність.

Побудовані моделі є оптимальними для обраного набору предикторів, однак не є вичерпними. Подальші дослідження можуть бути спрямовані на врахування додаткових факторів (мікрорайон, стан житла, поверховість), застосування нелінійних моделей (сплайни, GAM) або методів машинного навчання для покращення прогнозів. Також перспективним напрямом є вдосконалення динамічної моделі міграції шляхом урахування сезонності та зовнішніх шоків.

ПЕРЕЛІК ДЖЕРЕЛ ПОСИЛАННЯ

1. M² Bomber. Статистика оренди квартир у Києві. URL: <https://ua.m2bomber.com/stat/421866/view/kiiv?type=flat-rent> (дата звернення: 14.06.2026).
2. Державна служба статистики України. Банк даних: Статистична інформація. URL: <https://stat.gov.ua/uk/explorer> (дата звернення: дата звернення: 14.06.2026).
3. Національний банк України. Звіт про фінансову стабільність. Київ: НБУ, грудень 2024.
URL: https://bank.gov.ua/admin_uploads/article/FSR_2024-H2.pdf?v=18 (дата звернення: 14.06.2026).
4. Національний банк України. Звіт про фінансову стабільність. Київ: НБУ, грудень 2025.
URL: https://bank.gov.ua/admin_uploads/article/FSR_2025-H2.pdf (дата звернення: 14.06.2026).
5. Національний банк України. Офіційний курс гривні щодо іноземних валют.
URL: <https://bank.gov.ua/ua/markets/exchangerates> (дата звернення: 14.06.2026).
6. Овчиннікова О. Р., Куликов О. О. Детерміновані та стохастичні моделі міграції населення. *Вісник Київського національного університету технологій та дизайну*. 2010. № 5 (55). С. 158–163.
7. Чернуха Д. М. Apartment-Rent-in-Kyiv-2026. URL: <https://github.com/DanyloCherr/Appartment-Rent-in-Kyiv-2026/tree/main> (дата звернення: 17.06.2026).
8. Akaike H. A new look at the statistical model identification // *IEEE Transactions on Automatic Control*. 1974. Vol. 19, No. 6. P. 716–723.

9. Box G. E. P., Cox D. R. An Analysis of Transformations. *Journal of the Royal Statistical Society. Series B (Methodological)*. 1964. Vol. 26, No. 2. P. 211–243.
10. Breusch T. S., Pagan A. R. A Simple Test for Heteroscedasticity and Random Coefficient Variation. *Econometrica*. 1979. Vol. 47, No. 5. P. 1287–1294.
11. Cook R. D., Weisberg S. *Applied Regression, Including Computing and Graphics*. Wiley, 1999.
12. Durbin J., Watson G. S. Testing for serial correlation in least squares regression. II. *Biometrika*. 1951. Vol. 38, No. 1-2. P. 159–178.
13. Driscoll J. C., Kraay A. C. Consistent Covariance Matrix Estimation with Spatially Dependent Panel Data. *The Review of Economics and Statistics*. 1998. Vol. 80, No. 4. P. 549–560.
14. Iacoviello M. Geopolitical Risk (GPR) Index. URL:
https://www.matteoiacoviello.com/gpr_country_files/gprc_neeu.htm
 (дата звернення: 01.06.2026).
15. MacKinnon J. G., White H. Some heteroskedasticity-consistent covariance matrix estimators with improved finite sample properties. *Journal of Econometrics*. 1985. Vol. 29, No. 3. P. 305–325.
16. Mallows C. L. Some Comments on Cp. *Technometrics*. 1973. Vol. 15, No. 4. P. 661–675.
17. Montgomery D. C., Peck E. A., Vining G. G. *Introduction to Linear Regression Analysis*. 5th ed. Wiley, 2021.
18. Newey W. K., West K. D. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*. 1987. Vol. 55, No. 3. P. 703–708.

19. Ramsey J. B. Tests for Specification Errors in Classical Linear Least Squares Regression Analysis. *Journal of the Royal Statistical Society. Series B (Methodological)*. 1969. Vol. 31, No. 2. P. 350–371.
20. Shapiro S. S., Wilk M. B. An analysis of variance test for normality (complete samples). *Biometrika*. 1965. Vol. 52, No. 3-4. P. 591–611.
21. Schwarz G. Estimating the dimension of a model. *Annals of Statistics*. 1978. Vol. 6, No. 2. P. 461–464.

ДОДАТОК А. ДІАГНОСТИЧНІ ГРАФІКИ ДЛЯ МОДЕЛІ З К1 ПО ПЕРШОМУ ПЕРІОДУ




Рис. 13 — Ліворуч: графіки доданої змінної (avPlots). Праворуч: графіки компоненти плюс залишки (crPlots)

ДОДАТОК Б. РЕЗУЛЬТАТИ ПЕРЕБОРУ ВСІХ МОЖЛИВИХ ПІДМОДЕЛЕЙ ДЛЯ ДРУГОГО ПЕРІОДУ (22 СПОСТ.)

Таблиця 24 — Результати перебору підмоделей для другого періоду (22 спост.)

Ранг	Змінні	Adj R^2	p
За скоригованим R^2			
1	ІндМатСтан + ЧистГрнКред + Євро/Долар	0.9011	4
2	ІФС + ІндМатСтан + ЧистГрнКред + Євро/Долар	0.9008	5
3	ІндМатСтан + ЧистГрнКред + Євро/Долар + ІЦБ/ІЦЖП	0.8983	5
4	ІФС + ІндМатСтан + ЧистГрнКред	0.8977	4
5	ІндМатСтан + ЧистГрнКред	0.8968	3
За ВІС			
1	ІндМатСтан + ЧистГрнКред	-42.89	3
2	ІндМатСтан + ЧистГрнКред + Євро/Долар	-41.92	4
3	ЧистГрнКред	-41.27	2
4	ІФС + ІндМатСтан + ЧистГрнКред	-41.18	4
5	ІндМатСтан + ЧистГрнКред + ТемпЗмінКошт	-40.33	4
За C_p (найближче до p)			
1	ЧистГрнКред	2.82	2
2	ІндМатСтан + ЧистГрнКред + ТемпЗмінКошт	2.40	4
3	ЧистГрнКред + ІЦБ/ІЦЖП	3.62	3
4	ЧистГрнКред + ТемпЗмінКошт	4.02	3
5	ІФС + ІндМатСтан + РівДолар + ЧистГрнКред + Євро/Долар	4.45	6

ДОДАТОК В. ПРИТІК НАСЕЛЕННЯ ТА МОДЕЛЮВАННЯ




Рис. 14 — Ліворуч: кореляційна матриця, що містить дані про кількість прибулих. Праворуч: графік кількості прибулих в час та коробкова діаграма




Рис. 15 — Ліворуч: змодельована та офіційна чисельність населення Києва. Праворуч: змодельований притік. Довоєнні дані




Рис. 16 — Кореляційна матриця зі змодельованими змінними